

BioRAG: 让医学问答系统查得更准、答得更稳

对比学习微调 + Cross-Encoder 二次筛选

Group 2

BioASQ 12b Project Presentation

April 27, 2026

医学问答

RAG

InfoNCE

重排序

一句话介绍：我们在解决什么问题？

普通 RAG 像“开卷考试”

大模型不是直接凭记忆回答，而是先去查资料，再根据查到的资料生成答案。

但医学问答不能“查错资料”

医学文本里有很多专业名词、缩写和细微差别。资料看起来相关，不代表真的能回答问题。

目标：让系统查得更准，也不要被错误证据带偏。

为什么普通 RAG 在医学领域容易出错？

问题 1：术语不一定对得上

同一个医学概念可能有不同说法：

myocardial infarction

≈

heart attack

如果模型没有学过医学语义，就可能匹配失败。

问题 2：表面相关可能方向相反

有些文档关键词相似，但语义并不能支持答案。

看起来相关

→

自信答错

这就是 retrieval-induced hallucination。

医学问答的关键不是“有没有资料”，而是“资料靠不靠谱”。

BioRAG 整体流程



核心思想

检索器负责“找得全”，重排序模型负责“筛得准”，生成模型负责“根据可靠证据回答”。

第一步：Baseline 怎么做？

Zero-shot Baseline

- 使用冻结的 PubMedBERT bi-encoder
- 把问题和文档分别变成向量
- 用向量相似度找 Top-3 文档
- 直接交给 Qwen-2.5 生成答案

优点和缺点

优点：速度快。 缺点：只看“像不像”，不一定真正理解医学语义。

问题向量 → 文档向量



相似度打分



Top-3 直接生成

第二步：让检索器更懂医学

InfoNCE 可以通俗理解为“配对训练”

给模型很多组问题 - 正确资料，让它学会：

正确配对

问题 ↔ 相关文档

拉近

错误配对

问题 ↔ 不相关文档

推远

训练后，检索器不只是看关键词，而是更能理解**医学语义相关性**。

第三步：加一个“审稿人”筛证据

Bi-encoder 像快速初筛

- 问题和文档分开读
- 速度快
- 但细节判断不够强

Cross-encoder 像认真审稿

- 把问题和文档放在一起读
- 能看出更细的语义关系
- 用来从 Top-20 中选 Top-3

为什么有用？

它可以过滤掉“看起来相关、其实不能回答问题”的文档，减少错误证据进入生成模型。

实验设置

数据集

- BioASQ 12b 生物医学问答任务
- 抽取 500 个问题做测试
- 覆盖 Yes/No、Factoid、List、Summary
- 训练数据和测试问题不重叠

主要指标


Yes/No	Accuracy, Macro-F1
Factoid	Strict Accuracy, MRR
List	Recall, F-measure
生成质量	ROUGE-L, BERTScore

训练细节

3 个 epoch; 学习率 2×10^{-5} ; batch size 16; 最大长度 512。

训练过程：Loss 一直下降

Retriever Fine-tuning Loss (InfoNCE)
Dataset: BioASQ 12b (8887 pairs)



怎么读这张图？

- 一开始 loss 较高：模型还不会区分好资料和坏资料
- 前期快速下降：模型学得很快
- 后期趋于稳定：训练基本收敛

结论

检索器学到了更适合医学问答的表示空间。

实验结果：BioRAG 明显优于 Baseline

问题类型	指标	Baseline	BioRAG	提升
Yes/No	Accuracy	0.6364	0.7692	+20.9%
Yes/No	Macro-F1	0.6137	0.7410	+20.7%
Factoid	Strict Acc.	0.3869	0.4526	+17.0%
List	Recall	0.3242	0.4133	+27.5%
Overall	BERTScore	0.8643	0.8679	+0.4%

重点观察

- List Recall 提升最大：说明系统更能找全多个答案
- Yes/No Accuracy 提升明显：说明系统更不容易被错误证据带偏

速度权衡：慢了一点，但更可靠

平均每个问题耗时

Baseline: **2.60 秒**

BioRAG: **3.31 秒**

额外 +0.71 秒

为什么会变慢？

Cross-encoder 要认真检查 20 个候选文档，所以计算量更大。

为什么仍然值得？

多花不到 1 秒，换来 Yes/No 和 List 问题上 20% 左右的关键提升。医学问答里，**可靠性比快一点更重要**。

案例分析：有时候“不知道”比答错更好

问题

Does physical activity influence gut hormones?

标准答案：Yes

Baseline

检索到一篇关于 bed rest / inactivity 的弱相关文档，结果错误地回答 **No**。

自信但错误

BioRAG

重排序模型过滤掉弱证据，最终回答 **I don't know**。

保守但安全

在医学场景里，证据不足时承认不知道，通常比编造答案更安全。

讨论：BioRAG 到底改进了哪里？

检索器

更懂医学语义，不只依赖表面关键词。

重排序器

像“证据审稿人”，把弱相关材料筛掉。

生成模型

看到更干净的上下文，所以更不容易胡说。

局限性

Cross-encoder 会增加延迟；最终 LLM 还没有端到端微调；测试只用了 500 个问题，后续可以扩大规模验证。

主要结论

在医学问答中，RAG 的关键不只是“能查资料”，而是**能查到对的资料，并且不被错的资料带偏。**

- InfoNCE 微调：让 retriever 更懂医学语义
- Cross-encoder 重排序：过滤掉不可靠证据
- 实验结果：List Recall 和 Yes/No Accuracy 提升最明显
- 速度代价：平均只增加 0.71 秒

先对齐检索器，再验证证据，最后安全生成。

谢谢大家！欢迎提问。



BioASQ. *Tasks 12b, Synergy12, MultiCardioNER, BioNNE – Year 12.*

https://www.bioasq.org/participate/challenges_year_12



Lewis et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.* NeurIPS, 2020.

<https://arxiv.org/abs/2005.11401>



van den Oord, Li, and Vinyals. *Representation Learning with Contrastive Predictive Coding.*

arXiv:1807.03748, 2018. <https://arxiv.org/abs/1807.03748>



Gu et al. *Domain-Specific Language Model Pretraining for Biomedical Natural Language Processing.* ACM TCH, 2021.



Wang et al. *MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-trained Transformers.* NeurIPS, 2020.