

讲稿

Slide 1 | Title

大家好，我们今天汇报的题目是 **BioRAG: Enhancing Biomedical Question Answering via Contrastive Fine-Tuning and Cross-Encoder Re-ranking**。

简单来说，我们做的是一个面向生物医学问答的 RAG 系统。RAG 可以理解成一种“开卷考试”的大模型：它不是只依靠自己参数里记住的知识，而是会先检索外部文档，再根据检索到的材料生成答案。

但是在医学领域，问题会更复杂。因为医学问答涉及很多专业术语、缩写、同义表达和非常细微的语义差别。如果检索到的证据不可靠，大模型反而可能被错误证据带偏，生成一个看起来很合理但事实上错误的答案。

所以我们这项工作的核心问题是：**怎样让医学问答系统查得更准、答得更稳？**

我们的方案主要有两步：第一，用 contrastive fine-tuning 让 retriever 更懂医学语义；第二，用 cross-encoder re-ranking 对检索结果进行二次筛选，减少噪声证据进入生成模型。

Slide 2 | Motivation: Why Generic RAG Struggles in Biomedicine

这一页主要说明为什么普通 RAG 在生物医学场景下容易出错。

第一个问题是 **dense retrieval gap**。普通 embedding 模型通常是在通用文本上训练的，它可能不够理解医学术语之间的关系。比如 “myocardial infarction” 和 “heart attack” 实际上指的是同一个概念，但如果模型没有经过医学领域适配，就可能不能稳定地把它们匹配起来。反过来，有些术语表面看起来相似，但实际指向完全不同的生物机制，普通模型也可能混淆。

第二个问题是 **retrieval-induced hallucination**，也就是检索诱导幻觉。RAG 的生成模型会依赖检索到的上下文。如果检索出来的文档只是表面相关，甚至方向是错的，生成模型就可能基于错误证据给出一个自信但错误的回答。

所以在医学问答里，重点不是简单地“多查资料”，而是要查到真正能支持答案的资料。我们的目标就是提高 evidence quality，也就是证据质量。

Slide 3 | BioRAG at a Glance

这一页展示的是我们 BioRAG 的整体流程。

可以把这个系统理解成三个角色。

第一个角色是 **retriever**，它负责快速找资料。用户输入一个 biomedical query 以后，retriever 会从文档库中找出一批可能相关的文档。

第二个角色是 **re-ranker**，它负责认真筛资料。我们不会直接相信第一次检索结果，而是先取 top-20 candidates，然后让 cross-encoder re-ranker 重新判断这些文档到底和问题有多相关。

第三个角色是 **generator**，也就是最终的大语言模型。它只会看到 re-ranker 筛选后的 top-3 documents，然后基于这些更可靠的上下文生成答案。

所以 BioRAG 的核心逻辑可以概括为一句话：**先快速召回，再精细筛选，最后基于高质量证据生成答案。**

Slide 4 | Experimental Setup

这一页介绍实验设置。

我们使用的是 BioASQ 12b 数据集，这是一个生物医学问答数据集。由于计算资源有限，我们没有使用全部数据，而是抽取了 500 个 queries 做测试。同时我们使用 stratified random sampling，也就是分层随机抽样，保证不同问题类型都有覆盖。

这些问题主要包括四类：Yes/No、Factoid、List 和 Summary。

Yes/No 问题就是判断“是”或“不是”；Factoid 问题通常要求回答一个具体实体，比如疾病、基因或药物名称；List 问题要求系统列出多个答案；Summary 问题则要求生成一段概括性回答。

评价指标也对应不同问题类型。Yes/No 用 Accuracy 和 Macro-F1，Factoid 用 Strict Accuracy 和 MRR，List 用 Mean Recall 和 F-measure，生成质量则用 ROUGE-L 和 BERTScore 辅助评估。

这一页的重点是：我们不是只看模型语言是否流畅，而是从检索、判断、列举和生成多个角度评估系统是否真正可靠。

Slide 5 | Phase 1: Zero-Shot Baseline

在正式介绍我们的改进之前，我们先建立了一个 zero-shot baseline。

这个 baseline 使用 PubMedBERT-base 作为 frozen bi-encoder。所谓 bi-encoder，就是 query 和 document 分别编码成向量，然后通过 dot product 计算相似度。

PPT 上的公式：

$$s_{bi}(q, d) = E(q)^{\top} E(d)$$

意思很简单：如果 query 的向量和 document 的向量越接近，系统就认为这篇文档越相关。

这个方法的优点是速度快，因为向量检索效率很高。但它的问题是，query 和 document 是分开编码的，模型只能比较两个向量像不像，却很难理解更复杂的 query-document interaction。

在医学问答里，这个问题会很明显。因为医学文本里一个否定词、一个实验条件、一个语义方向的变化，都可能导致答案完全不同。Baseline 很可能检索到“看起来相关、其实不能回答问题”的文档。

所以 baseline 是一个很好的对照：它代表一个比较朴素的 RAG 系统，后面我们会看 BioRAG 如何在它基础上改进。

Slide 6 | Phase 2: Contrastive Fine-Tuning

第二阶段是 contrastive fine-tuning，也就是用 InfoNCE loss 微调 retriever。

这个部分看起来比较技术，但直观理解其实很简单：我们希望模型学会把“问题”和“真正相关的文档”拉近，把“不相关的文档”推远。

训练时，每个 query 都有一个 positive document，也就是正确相关文档。同一个 batch 里的其他 documents 会被当作 negative samples。模型的任务就是：在这些候选文档中，把真正相关的那一个选出来。

所以 InfoNCE 本质上是在训练一个更好的 embedding space。训练以后，医学语义上真正相关的 query-document pair 会更接近；只是表面词汇相似但不能回答问题的文档会被推远。

这一步的意义是：让 retriever 从“看关键词像不像”升级为“理解医学语义是否相关”。

Slide 7 | Phase 3: Cross-Encoder Re-ranking

第三阶段是 cross-encoder re-ranking。

虽然 contrastive fine-tuning 能改善 retriever，但 bi-encoder 本身仍然有结构限制。它把 query 和 document 分开编码，最后只用一个相似度分数比较。这种方法快，但会压缩掉很多细节。

Cross-encoder 的方式不一样。它会把 query 和 document 放在一起输入模型，比如：

$$[CLS] \ q \ [SEP] \ d \ [SEP]$$

这样模型可以直接看到问题和文档之间的每一个 token 关系，通过 full self-attention 判断这篇文档是不是真的能回答这个问题。

所以 cross-encoder 更像一个“证据审查员”。Bi-encoder 先快速找出 top-20 candidates，cross-encoder 再从这 20 个里面精挑细选出 top-3。

这一阶段的核心作用不是增加检索数量，而是提高最终上下文的质量。也就是说，它帮助我们过滤掉那些表面相关、但实际上可能误导生成模型的文档。

Slide 8 | Training Convergence

这一页展示的是 retriever fine-tuning 的 loss 曲线。

这里大家不用记住每一个具体数值，主要看趋势：loss 从一开始比较高，随后快速下降，最后逐渐稳定。

这说明训练是有效的。一开始，模型还不太会区分相关医学文档和噪声文档，所以 loss 比较高。经过训练后，模型逐渐学会把 positive documents 和 negative documents 分开，所以 loss 下降。

到第三个 epoch 左右，loss 稳定在较低水平，说明模型基本收敛了。也就是说，contrastive fine-tuning 成功地把 retriever 的 embedding space 调整到了更适合 biomedical QA 的状态。

这一页可以总结为：训练曲线证明，**retriever** 确实学会了更好地区分有用证据和噪声证据。

Slide 9 | Quantitative Results

这一页是最重要的实验结果。

我们可以从三个重点来看。

第一，Yes/No Accuracy 从 0.6364 提升到 0.7692，提升了 20.9%。这说明 BioRAG 在判断类问题上更加可靠，不容易被错误或矛盾证据带偏。

第二，Factoid Strict Accuracy 从 0.3869 提升到 0.4526，提升了 17.0%。这说明系统在回答具体事实，比如某个疾病、基因或药物名称时，也比 baseline 更准确。

第三，List Recall 从 0.3242 提升到 0.4133，提升了 27.5%，这是最明显的提升。List questions 通常要求系统找出多个实体，这些实体可能分散在不同文档中。因此 List Recall 的提升说明，fine-tuned retriever 更擅长收集分散的医学证据。

所以这页的核心结论是：**BioRAG** 的提升不是单一指标上的偶然提升，而是在多种问题类型上都有稳定改进。

更直观地说：检索到的证据更好，最终答案也更可靠。

Slide 10 | Efficiency Analysis

当然，引入 cross-encoder 会带来额外计算成本。

Baseline 的平均延迟是 2.60 秒，而 BioRAG 的平均延迟是 3.31 秒。所以我们的系统多花了 0.71 秒。

这个额外开销主要来自 cross-encoder。因为它要对每个问题的 20 个候选文档逐一进行 query-document matching，而不是简单做向量点积。

但是我们认为这个 trade-off 是值得的。因为多花不到一秒钟，换来的是 Yes/No Accuracy 和 List Recall 上超过 20% 的提升。

在普通聊天任务中，速度可能非常重要；但在 biomedical QA 中，可靠性更重要。用户更希望系统慢一点但不要被错误证据带偏。

所以这一页的结论是：**BioRAG** 稍微慢了一点，但显著更可靠。

Slide 11 | Case Study: Safety Through Abstention

这一页用一个具体案例说明为什么 re-ranking 很重要。

问题是：**Does physical activity influence gut hormones?**

标准答案是 Yes。

Baseline 错误地回答了 No。原因是它检索到了一篇关于 bed rest 和 inactivity 的文档。这个文档和 physical activity 在词面上有关联，但它并不能真正回答原问题。Baseline 被这个弱相关文档带偏，最后生成了一个看似有依据但事实上错误的答案。

BioRAG 的表现不同。Cross-encoder re-ranker 识别出这个文档和问题之间的语义关系不够强，因此没有把它作为高质量证据交给生成模型。最后系统回答的是 “I don't know”。

从严格准确率看，“I don't know” 当然不是最佳答案，因为标准答案是 Yes。但从安全性角度看，它比自信地答错更好。

尤其在医学场景里，当证据不足时，系统应该更保守。不知道，比编造一个错误答案更安全。

所以这个案例说明，re-ranker 不只是提高分数，它还起到了 **safety gate** 的作用，也就是在生成之前阻止低质量证据进入模型。

Slide 12 | Discussion

这一页我们讨论 BioRAG 到底改进了什么。

第一，它改进了 retriever。通过 InfoNCE fine-tuning，retriever 不再只是依赖表面词汇相似，而是更能捕捉医学语义相关性。

第二，它改进了 evidence quality。Cross-encoder re-ranker 可以更细致地判断 query 和 document 的关系，从而过滤掉看起来相关但实际不可靠的文档。

第三，它间接改进了 generation。我们没有直接 fine-tune 最后的 generator，但由于 generator 看到的是更干净、更可靠的 context，最终答案自然也更稳定。

这里还有一个值得注意的现象：ROUGE-L 可能会略有下降。这不一定说明系统变差了。因为 baseline 有时会生成更长、更啰嗦的答案，里面可能碰巧包含一些标准答案里的词，从而提高 n-gram overlap。但 BioRAG 的答案更直接、更简洁，所以在 ROUGE-L 上可能不占优势。BERTScore 的提升反而说明语义质量是有改善的。

所以整体来看，BioRAG 的价值不只是指标提升，而是提高了整个 evidence pipeline 的可信度。

Slide 13 | Limitations

当然，我们的方法也有局限。

第一，cross-encoder 会增加延迟。在我们的实验中这个延迟是可以接受的，但如果未来需要对几百篇文档进行 re-ranking，计算成本可能会变成瓶颈。

第二，我们目前没有 fine-tune generator。也就是说，最后负责生成答案的大语言模型是 frozen 的。未来如果进行 end-to-end fine-tuning，可能会进一步提升答案格式和表达一致性。

第三，我们的评估是在 500 个 queries 上完成的。这个样本可以说明趋势，但如果要证明系统在更大规模、更复杂语料上的泛化能力，还需要进一步实验。

所以我们的结论不是说 BioRAG 已经完美，而是说它证明了一个方向：在生物医学问答中，domain adaptation 和 evidence verification 都非常关键。

Slide 14 | Conclusion

最后总结一下。

我们提出了 BioRAG，一个面向 biomedical question answering 的 RAG 系统。

它的核心思想可以分成三步：

第一，用 contrastive fine-tuning 对齐 retriever，让它更理解医学语义。

第二，用 cross-encoder re-ranker 验证检索证据，把噪声文档过滤掉。

第三，让 generator 基于更可靠的 context 生成答案。

实验结果表明，BioRAG 相比 zero-shot baseline 在多个指标上都有提升，尤其是 List Recall 和 Yes/No Accuracy。同时，系统只增加了 0.71 秒的平均延迟。

所以我们最终想强调的是：在医学这种高风险领域，RAG 的关键不是简单地“能不能查资料”，而是 **能不能查到正确资料，并且避免被错误资料带偏。**

可以用一句话作为总结：

Align the retriever, verify the evidence, and generate safely.

我的汇报到这里结束，谢谢大家。